# Практическое использование BLAST

Выполнила Узенюк Е.И. Б06-301

Использовался веб-интерфейс NCBI BLAST.

## Задание 1.

### 1.1

Последовательность:
>NP_000537.3 cellular tumor antigen p53 isoform a [Homo sapiens]
MEEPQSDPSVEPPLSQETFSDLWKLLPENNVLSPLPSQAMDDLMLSPDDIEQWFTEDPGP
DEAPRMPEAA
PPVAPAPAAPTPAAPAPAPSWPLSSSVPSQKTYQGSYGFRLGFLHSGTAKSVTCTYSPALN
KMFCQLAKT
CPVQLWVDSTPPPGTRVRAMAIYKQSQHMTEVVRRCPHHERCSDSDGLAPPQHLIRVEGN
LRVEYLDDRN
TFRHSVVVPYEPPEVGSDCTTIHYNYMCNSSCMGGMNRRPILTIITLEDSSGNLLGRNSFEV
RVCACPGR
DRRTEEENLRKKGEPHHELPPGSTKRALPNNTSSSPQPKKKPLDGEYFTLQIRGRERFEMF
RELNEALEL
KDAQAGKEPGGSRAHSSHLKSKKGQSTSRHKKLMFKTEGPDSD
Запустили BLASTp по базе данных Non-redundant protein sequences:

Результаты:

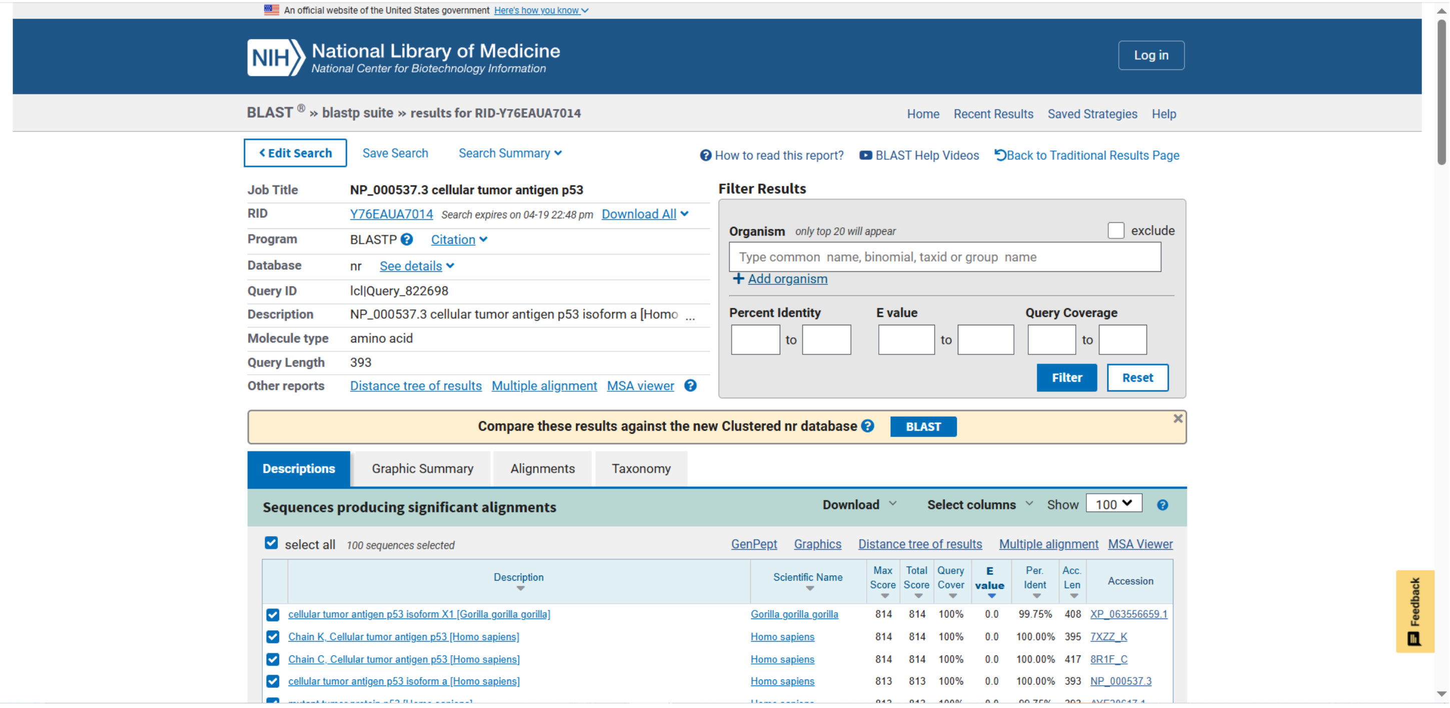


## 1.2.

1. Название: cellular tumor antigen p53 isoform X1. Организм: Gorilla gorilla gorilla.
2. E-value = 0 (то есть вероятность случайного совпадения меньше, чем округление для компьютера)
3. Это означает что вероятность случайного такого же или лучшего выравнивания в базе nr очень мала.А так как база большая, то найденная последовательность практически такая же что искалась. Raw Score это сумма баллов за совпадения/замены по матрице, но он не учитывает размер базы данных. Чем больше база, тем выше вероятность случайного похожего совпадения. При одном и том же Raw Score в большой базе это может быть случайность, а в маленькой значимое совпадение. E-value нормирует с учётом размера базы, поэтому говорит о статистической значимости совпадения.

# Задание 2

## 2.1

Последовательность:
>NM_000518.5 Homo sapiens hemoglobin subunit beta (HBB), mRNA
ACATTTGCTTCTGACACAACTGTGTTCACTAGCAACCTCAAACAGACACCATGGTGCATCTGACTCCTGA
GGAGAAGTCTGCCGTTACTGCCCTGTGGGGCAAGGTGAACGTGGATGAAGTTGGTGGTGAGGCCCTGGGC

AGGCTGCTGGTGGTCTACCCTTGGACCCAGAGGTTCTTTGAGTCCTTTGGGGATCTGTC
CACTCCTGATG
CTGTTATGGGCAACCCTAAGGTGAAGGCTCATGGCAAGAAAGTGCTCGGTGCCTTTAGT
GATGGCCTGGC
TCACCTGGACAACCTCAAGGGCACCTTTGCCACACTGAGTGAGCTGCACTGTGACAAG
CTGCACGTGGAT
CCTGAGAACTTCAGGCTCCTGGGCAACGTGCTGGTCTGTGTGCTGGCCCATCACTTTG
GCAAAGAATTCA
CCCCACCAGTGCAGGCTGCCTATCAGAAAGTGGTGGCTGGTGTGGCTAATGCCCTGGC
CCACAAGTATCA
CTAAGCTCGCTTTCTTGCTGTCCAATTTCTATTAAAGGTTCCTTTGTTCCCTAAGTCCAAC
TACTAAACT
GGGGGATATTATGAAGGGCCTTGAGCATCTGGATTCTGCCTAATAAAAAACATTTATTTTC
ATTGCAA

1. У нас есть нуклеотидная последовательность (мРНК), а ищем гомологичные белки, т.е. нужно использовать **blastx**, т.к. он транслирует нуклеотидный запрос во все 6 рамок считывания и ищет совпадения в белковой базе данных.
   Остальные инструменты нужно использовать, когда:
   **Blastn**
   Ищем: Нуклеотидную посл.
   Где: Нукл. посл.
   **Blastp**
   Ищем: Белок
   Где: Белки
   **tblastn**
   Ищем: Белок
   Где: Нукл. посл.
   **tblastx**
   ИЩЕМ НА УРОВНЕ БЕЛКА
   Ищем: Нукл. посл.
   Где: Нукл. посл.

# 2.2.

Результат запуска blastx см. ниже.

# 2.3.

Верной оказалась рамка считывания +3 (см. ниже картинку).

# 2.4.

blastx надёжнее, т.к. автоматически транслирует последовательность во все 6 рамок считывания и ищет по всем сразу. При ручной трансляции через сторонний транслятор нужно заранее знать правильную рамку считывания, т.к. если выбрать неверную, то получится неправильный белок и поиск не найдёт гомологов. (+ в мРНК могут быть UTR-области, ошибки аннотации или сдвиги рамки, blastx учитывает это)

BLAST ® » blastx » results for RID-Y79D22K3014

Home Recent Results Saved Strategies Help

Edit Search | Save Search | Search Summary

How to read this report? | BLAST Help Videos | Back to Traditional Results Page

| | |
|---|---|
| Job Title | NM_000518.5 Homo sapiens hemoglobin subunit |
| RID | Y79D22K3014 *Search expires on 04-19 23:39 pm* Download All |
| Program | BLASTX Citation |
| Database | nr See details |
| Query ID | lcl\|Query_4529516 |
| Description | NM_000518.5 Homo sapiens hemoglobin subunit beta (H ... |
| Molecule type | dna |
| Query Length | 628 |
| Other reports | |

**Filter Results**

**Organism** *only top 20 will appear* exclude

Type common name, binomial, taxid or group name

+ Add organism

**Percent Identity** to **E value** to **Query Coverage** to

Filter Reset

Compare these results against the new Clustered nr database BLAST

Descriptions | Graphic Summary | Alignments | Taxonomy

**Sequences producing significant alignments** Download Select columns Show 100

select all *100 sequences selected* GenPept Graphics

| Description | Scientific Name | Max Score | Total Score | Query Cover | E value | Per. Ident | Acc. Len | Accession |
|---|---|---|---|---|---|---|---|---|
| hemoglobin beta, partial [synthetic construct] | synthetic construct | 301 | 301 | 70% | 1e-101 | 100.00% | 148 | AAX37051.1 |
| hemoglobin beta, partial [synthetic construct] | synthetic construct | 301 | 301 | 70% | 1e-101 | 100.00% | 148 | AAX29557.1 |
| hemoglobin subunit beta [Homo sapiens] | Homo sapiens | 301 | 301 | 70% | 2e-101 | 100.00% | 147 | NP_000509.1 |
| hemoglobin subunit beta [Gorilla gorilla gorilla] | Gorilla gorilla go... | 300 | 300 | 70% | 6e-101 | 99.32% | 147 | XP_018891709.1 |
| beta globin chain variant [Homo sapiens] | Homo sapiens | 299 | 299 | 70% | 6e-101 | 99.32% | 147 | AAN84548.1 |
| beta-globin [Homo sapiens] | Homo sapiens | 299 | 299 | 70% | 6e-101 | 99.32% | 147 | ACU56984.1 |
| beta globin [Homo sapiens] | Homo sapiens | 299 | 299 | 70% | 6e-101 | 99.32% | 147 | AAZ39780.1 |
| hemoglobin beta chain [Homo sapiens] | Homo sapiens | 299 | 299 | 70% | 8e-101 | 99.32% | 147 | AAD19696.1 |

Feedback

*100 sequences selected* ?

Download GenPept Graphics ▼ Next ▲ Previous ◀Descriptions

**hemoglobin beta, partial [synthetic construct]**

**Sequence ID:** **AAX37051.1** **Length:** **148** **Number of Matches:** **1**

**Range 1: 1 to 147** GenPept Graphics ▼ Next Match ▲ Previous Match

| Score | Expect | Method | Identities | Positives | Gaps | Frame |
|---|---|---|---|---|---|---|
| 301 bits(771) | 1e-101 | Compositional matrix adjust. | 147/147(100%) | 147/147(100%) | 0/147(0%) | +3 |

```
Query  51   MVHLTPEEKSAVTALWGKVNVDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPK  230
            MVHLTPEEKSAVTALWGKVNVDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPK
Sbjct  1    MVHLTPEEKSAVTALWGKVNVDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPK  60

Query  231  VKAHGKKVLGAFSDGLAHLDNLKGTFATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFG  410
            VKAHGKKVLGAFSDGLAHLDNLKGTFATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFG
Sbjct  61   VKAHGKKVLGAFSDGLAHLDNLKGTFATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFG  120

Query  411  KEFTPPVQAAYQKVVAGVANALAHKYH  491
            KEFTPPVQAAYQKVVAGVANALAHKYH
Sbjct  121  KEFTPPVQAAYQKVVAGVANALAHKYH  147
```

# Задание 3

## 3.1

Белок:
>NP_005359.1 myoglobin isoform 1 [Homo sapiens]
MGLSDGEWQLVLNVWGKVEADIPGHGQEVLIRLFKGHPETLEKFDKFKHLKSEDEMKASE
DLKKHGATVL
TALGGILKKKGHHEAEIKPLAQSHATKHKIPVKYLEFISECIIQVLQSKHPGDFGADAQGAMN
KALELFR
KDMASNYKELGFQG

Параметры запуска:

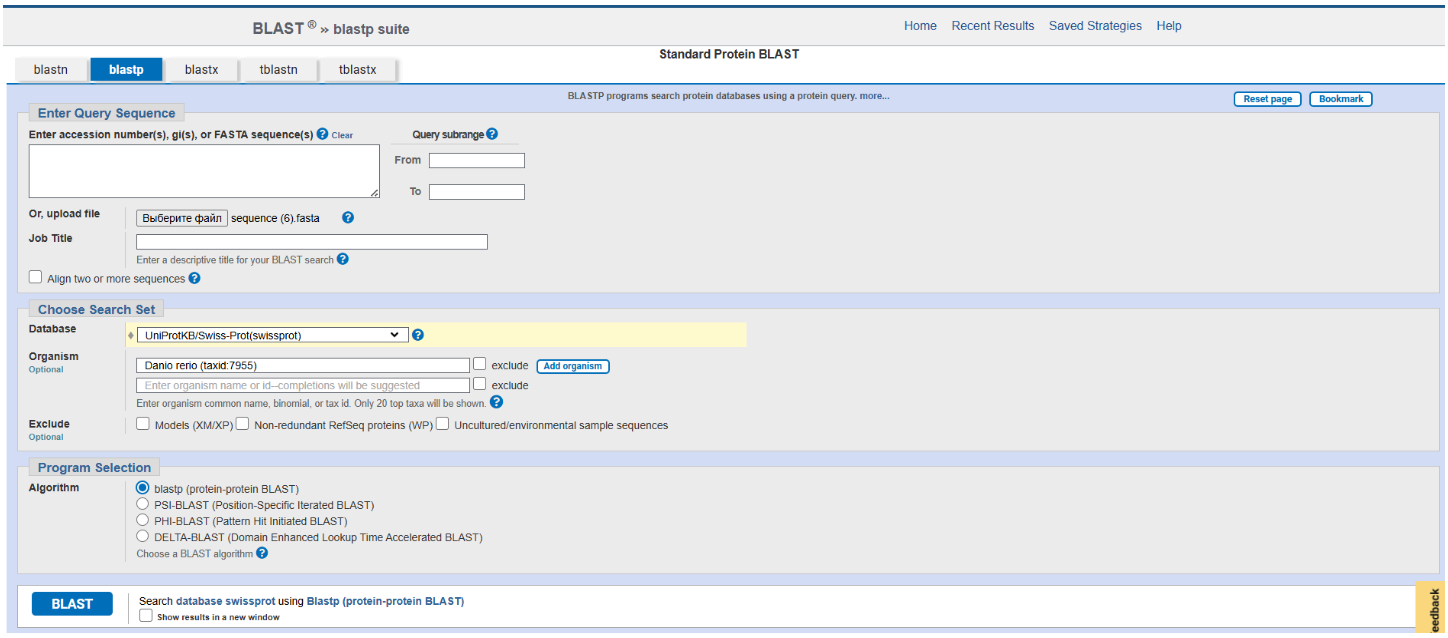
BLAST ® » blastp suite
Home Recent Results Saved Strategies Help
Standard Protein BLAST
blastn blastp blastx tblastn tblastx
BLASTP programs search protein databases using a protein query. more...
Reset page Bookmark
Enter Query Sequence
Enter accession number(s), gi(s), or FASTA sequence(s) Clear
Query subrange
From
To
Or, upload file
Выберите файл sequence (6).fasta
Job Title
Enter a descriptive title for your BLAST search
Align two or more sequences
Choose Search Set
Database
UniProtKB/Swiss-Prot(swissprot)
Organism
Optional
Danio rerio (taxid:7955)
exclude
Add organism
Enter organism name or id--completions will be suggested
exclude
Enter organism common name, binomial, or tax id. Only 20 top taxa will be shown.
Exclude
Optional
Models (XM/XP) Non-redundant RefSeq proteins (WP) Uncultured/environmental sample sequences
Program Selection
Algorithm
blastp (protein-protein BLAST)
PSI-BLAST (Position-Specific Iterated BLAST)
PHI-BLAST (Pattern Hit Initiated BLAST)
DELTA-BLAST (Domain Enhanced Lookup Time Accelerated BLAST)
Choose a BLAST algorithm
BLAST
Search database swissprot using Blastp (protein-protein BLAST)
Show results in a new window
eedback

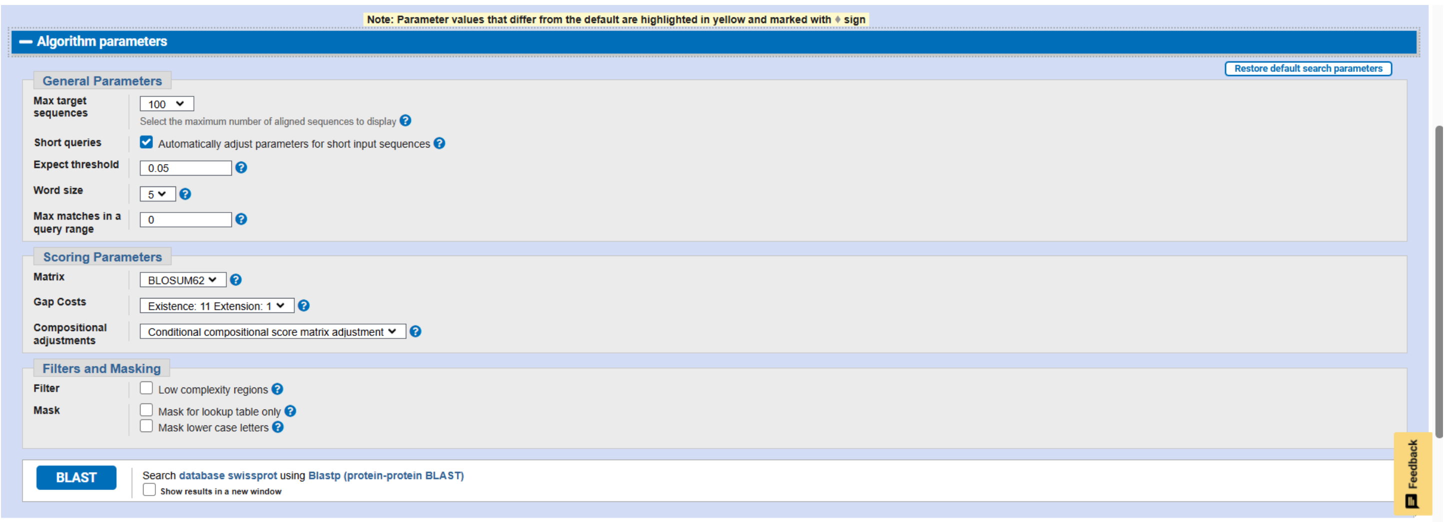
Note: Parameter values that differ from the default are highlighted in yellow and marked with ♦ sign
— Algorithm parameters
Restore default search parameters
General Parameters
Max target sequences
100
Select the maximum number of aligned sequences to display
Short queries
Automatically adjust parameters for short input sequences
Expect threshold
0.05
Word size
5
Max matches in a query range
0
Scoring Parameters
Matrix
BLOSUM62
Gap Costs
Existence: 11 Extension: 1
Compositional adjustments
Conditional compositional score matrix adjustment
Filters and Masking
Filter
Low complexity regions
Mask
Mask for lookup table only
Mask lower case letters
BLAST
Search database swissprot using Blastp (protein-protein BLAST)
Show results in a new window
Feedback

Результаты запуска с параметрами по умолчанию по базе SwissProt с матрицей BLOSUM62:

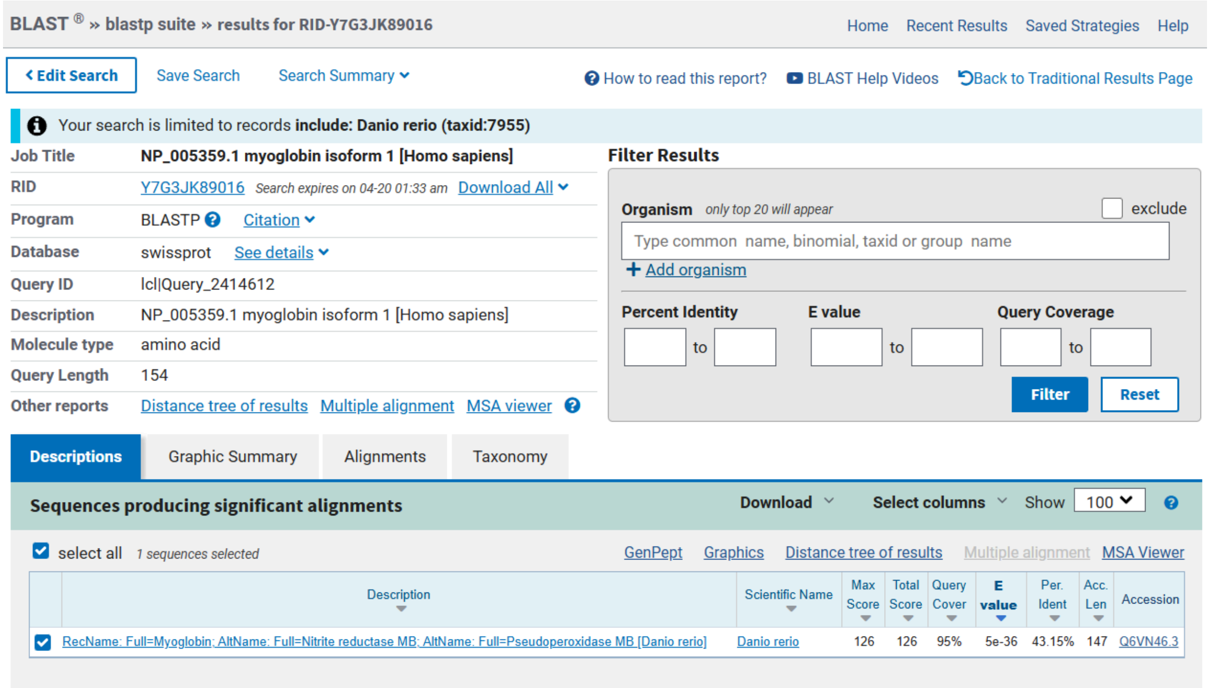


Значения запуска: E-value = 5*10^(-36), Bit Score = 126, Query Cover = 43,15%.

# 3.2+3.3

Новые параметры запуска с матрицей PAM30:

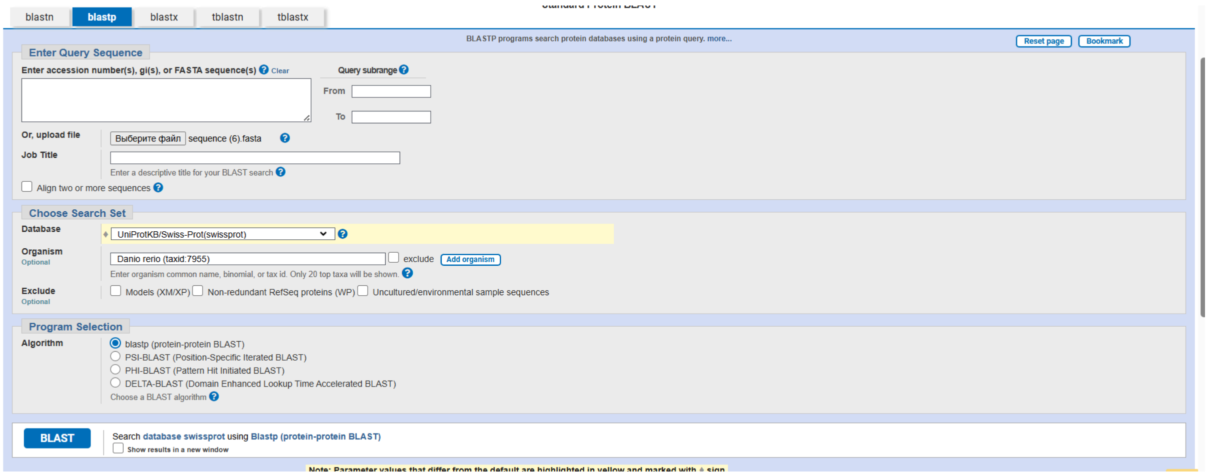

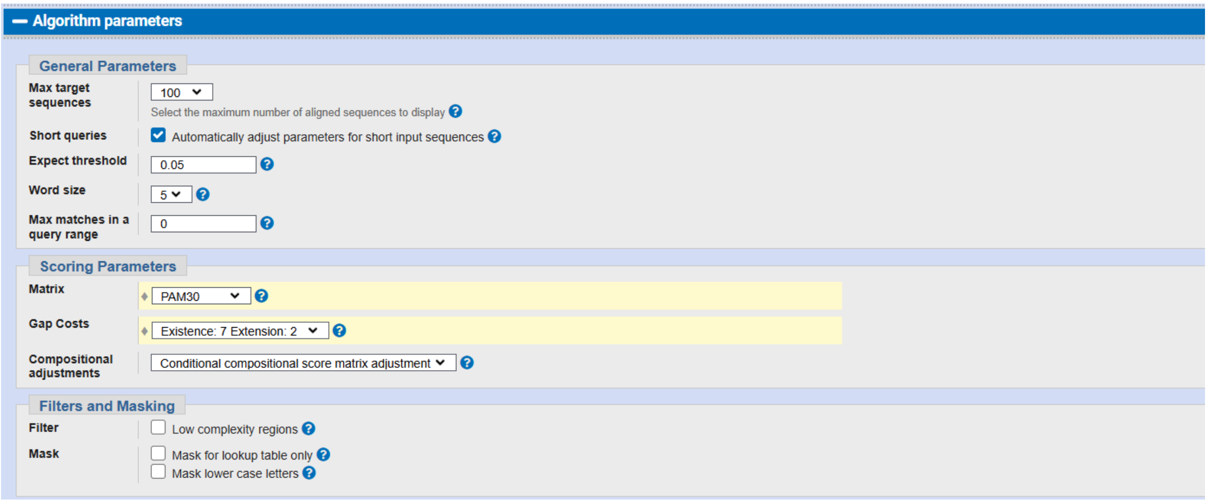


Результаты запуска с PAM30:

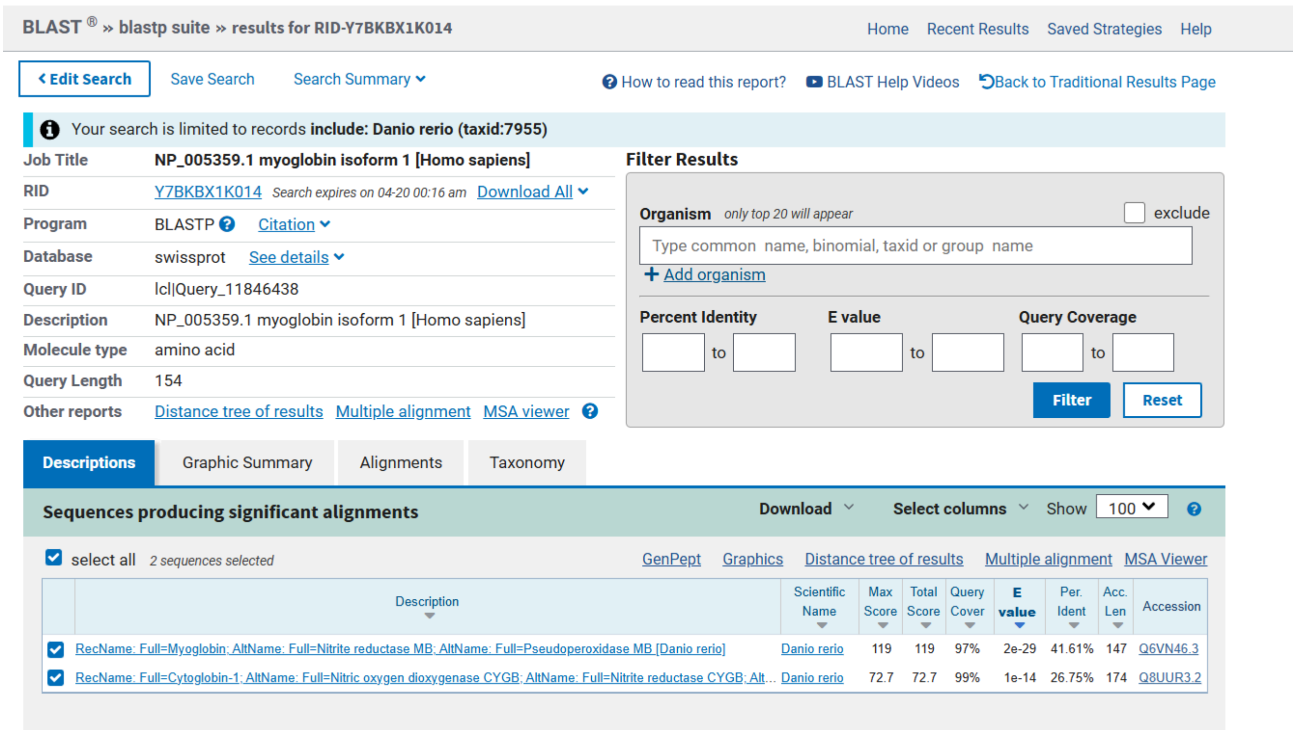

Два результата. Значения первого: E-value = 2*10^(-29), Bit Score = 119, Query Cover = 41,61%.

## 3.4.

PAM30 создана для близкородственных последовательностей, она сильно штрафует за любые замены. Поэтому на умеренно далёких гомологах (человек и Danio rerio) она даёт худший E-value, так как замены между ними неизбежны. BLOSUM62 создана для умеренно далёких последовательностей и лучше прощает консервативные замены, поэтому даёт более значимый E-value в данном случае.

PAM30 лучше подходит для поиска близких гомологов, BLOSUM62  для эволюционно далёких, как в этом задании.

# Задание 4.

Последовательность:
>NP_009225.1 breast cancer type 1 susceptibility protein isoform 1 [Homo sapiens]
MDLSALRVEEVQNVINAMQKILECPICLELIKEPVSTKCDHIFCKFCMLKLLNQKKGPSQCPL
CKNDITK
RSLQESTRFSQLVEELLKIICAFQLDTGLEYANSYNFAKKENNSPEHLKDEVSIIQSMGYRNR
AKRLLQS
EPENPSLQETSLSVQLSNLGTVRTLRTKQRIQPQKTSVYIELGSDSSEDTVNKATYCSVGDQ
ELLQITPQ
GTRDEISLDSAKKAACEFSETDVTNTEHHQPSNNDLNTTEKRAAERHPEKYQGSSVSNLHV
EPCGTNTHA
SSLQHENSSLLLTKDRMNVEKAEFCNKSKQPGLARSQHNRWAGSKETCNDRRTPSTEKKV
DLNADPLCER
KEWNKQKLPCSENPRDTEDVPWITLNSSIQKVNEWFSRSDELLGSDDSHDGESESNAKVA
DVLDVLNEVD
EYSGSSEKIDLLASDPHEALICKSERVHSKSVESNIEDKIFGKTYRKKASLPNLSHVTENLIIG
AFVTEP
QIIQERPLTNKLKRKRRPTSGLHPEDFIKKADLAVQKTPEMINQGTNQTEQNGQVMNITNSG
HENKTKGD
SIQNEKNPNPIESLEKESAFKTKAEPISSSISNMELELNIHNSKAPKKNRLRRKSSTRHIHALE
LVVSRN
LSPPNCTELQIDSCSSSEEIKKKKYNQMPVRHSRNLQLMEGKEPATGAKKSNKPNEQTSKR
HDSDTFPEL
KLTNAPGSFTKCSNTSELKEFVNPSLPREEKEEKLETVKVSNNAEDPKDLMLSGERVLQTE
RSVESSSIS
LVPGTDYGTQESISLLEVSTLGKAKTEPNKCVSQCAAFENPKGLIHGCSKDNRNDTEGFKY
PLGHEVNHS
RETSIEMEESELDAQYLQNTFKVSKRQSFAPFSNPGNAEEECATFSAHSGSLKKQSPKVTF
ECEQKEENQ

GKNESNIKPVQTVNITAGFPVVGQKDKPVDNAKCSIKGGSRFCLSSQFRGNETGLITPNKHG
LLQNPYRI
PPLFPIKSFVKTKCKKNLLEENFEEHSMSPEREMGNENIPSTVSTISRNNIRENVFKEASSSN
INEVGSS
TNEVGSSINEIGSSDENIQAELGRNRGPKLNAMLRLGVLQPEVYKQSLPGSNCKHPEIKKQE
YEEVVQTV
NTDFSPYLISDNLEQPMGSSHASQVCSETPDDLLDDGEIKEDTSFAENDIKESSAVFSKSVQ
KGELSRSP
SPFTHTHLAQGYRRGAKKLESSEENLSSEDEELPCFQHLLFGKVNNIPSQSTRHSTVATECL
SKNTEENL
LSLKNSLNDCSNQVILAKASQEHHLSEETKCSASLFSSQCSELEDLTANTNTQDPFLIGSSK
QMRHQSES
QGVGLSDKELVSDDEERGTGLEENNQEEQSMDSNLGEAASGCESETSVSEDCSGLSSQS
DILTTQQRDTM
QHNLIKLQQEMAELEAVLEQHGSQPSNSYPSIISDSSALEDLRNPEQSTSEKAVLTSQKSSE
YPISQNPE
GLSADKFEVSADSSTSKNKEPGVERSSPSKCPSLDDRWYMHSCSGSLQNRNYPSQEELIK
VVDVEEQQLE
ESGPHDLTETSYLPRQDLEGTPYLESGISLFSDDPESDPSEDRAPESARVGNIPSSTSALKV
PQLKVAES
AQSPAAAHTTDTAGYNAMEESVSREKPELTASTERVNKRMSMVVSGLTPEEFMLVYKFARK
HHITLTNLI
TEETTHVVMKTDAEFVCERTLKYFLGIAGGKWVVSYFWVTQSIKERKMLNEHDFEVRGDVV
NGRNHQGPK
RARESQDRKIFRGLEICCYGPFTNMPTDQLEWMVQLCGASVVKELSSFTLGTGVHPIVVVQ
PDAWTEDNG
FHAIGQMCEAPVVTREWVLDSVALYQCQELDTYLIPQIPHSHY

Параметры запуска:

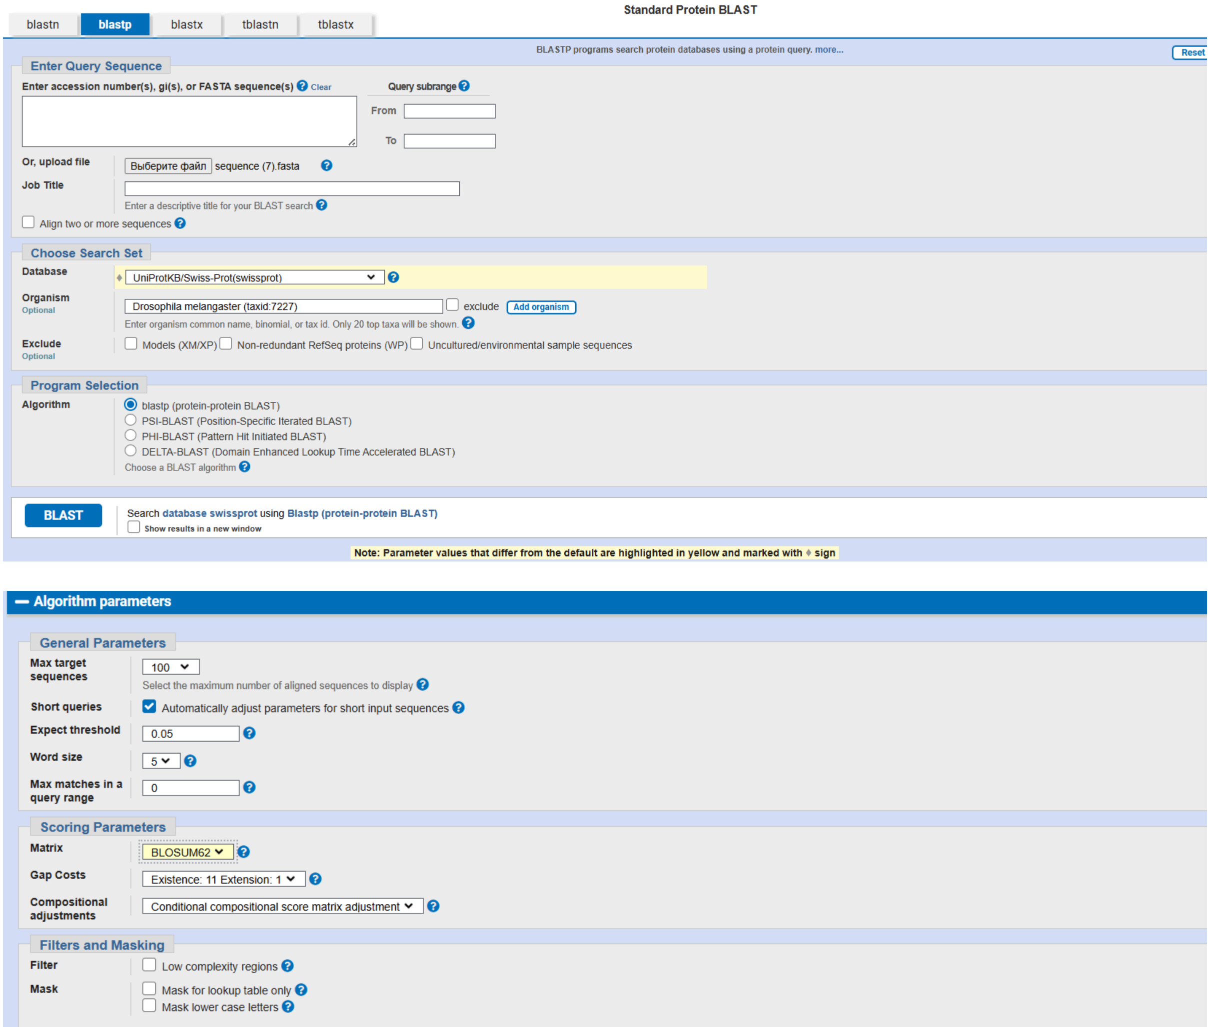


Результаты запуска:

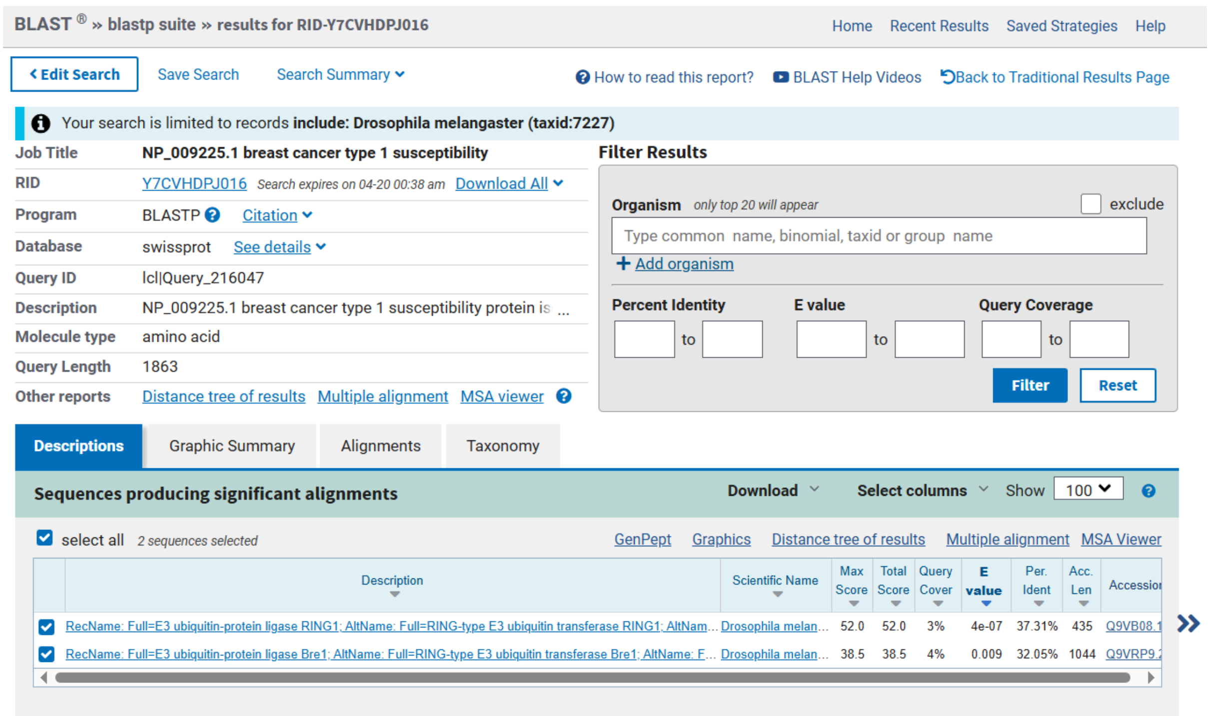

# 4.3.

Лучший хит: RecName: Full=E3 ubiquitin-protein ligase RING1; AltName: Full=RING-type E3 ubiquitin transferase RING1; AltName: Full=Sex comb extra protein; AltName: Full=dRING protein; AltName: Full=dRING1 [Drosophila melanogaster]

# 4.4.

Query Cover = 3%, Per. Ident = 37,31%. Белок очень слабо похож на человеческий. Query Cover = 3%, т.е. маленький фрагмент запроса нашёл совпадение. Идентичность 37% в этом коротком участке, т.е. небольшое сходство есть. Белок можно считать очень далёким гомологом или функционально неродственным человеческому.

# 4.5.

На вкладке Graphics:

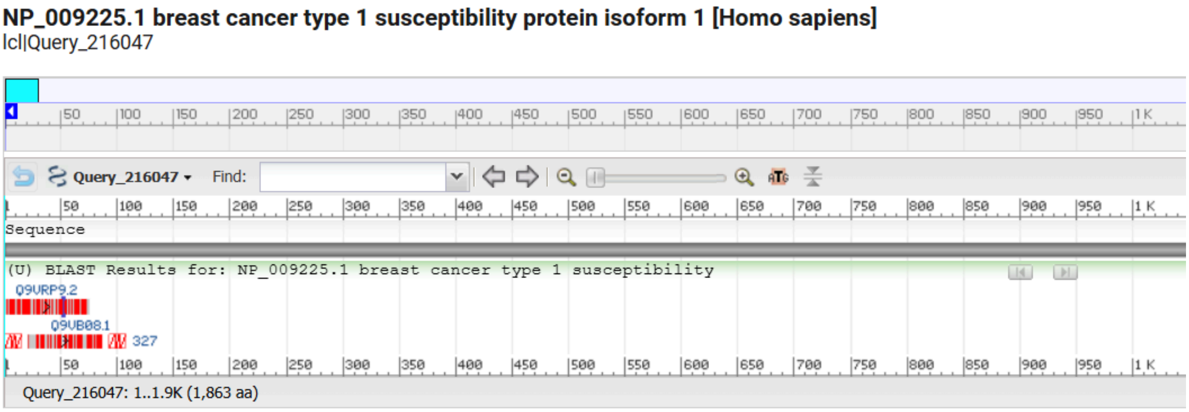


На графике видно, что совпадения покрывают лишь небольшой участок в начале последовательности, тогда как остальная часть белка не выровнена.

Белок сохранился не целиком, а консервативен только отдельный домен в N-концевой области. Этот домен в ходе эволюции находился под сильным функциональным отбором и сохранился у разных организмов, тогда как остальная часть белка эволюционировала быстрее и стала уникальной для человека. Такая картина типична для многодоменных белков.